Gesten- und Sprachsteuerung für einen mobilen Roboter mittels Kinect for Windows unter Java

Studienarbeit

für die Prüfung zum

Bachelor of Science

der Angewandte Informatik

an der Dualen Hochschule Baden-Württemberg Karlsruhe

von

Simon Ebner, Volker Werling

Mai 2013

Bearbeitungszeitraum	12 Wochen
Matrikelnummer, Kurs	5837963 7012192, TAI10B2
Gutachter	Prof. Hans-Jörg Haubner

Erklärung

Wir erklären hiermit ehrenwörtlich:

1. dass wir unsere Studienarbeit mit dem Thema *Gesten- und Sprachsteuerung fuer einen mobilen Roboter mittels Kinect for Windows unter Java* ohne fremde Hilfe angefertigt haben;
2. dass wir die Übernahme wörtlicher Zitate aus der Literatur sowie die Verwendung der Gedanken anderer Autoren an den entsprechenden Stellen innerhalb der Arbeit gekennzeichnet haben;
3. dass wir unsere Studienarbeit bei keiner anderen Prüfung vorgelegt haben;
4. dass die eingereichte elektronische Fassung exakt mit der eingereichten schriftlichen Fassung übereinstimmt.

Wir sind uns bewusst, dass eine falsche Erklärung rechtliche Folgen haben wird.

Karlsruhe, Mai 2013

Simon Ebner, Volker Werling

Zusammenfassung

Durch den Fortschritt der Technik wird der Wunsch des Menschen sich bestimmte Arbeiten zu erleichtern immer größer. Automaten, sogennante Roboter, werden eingesetzt um Menschen ihnen unliebsame, schwere oder auch gefährliche Aufgaben abzunehmen. Da Roboter mehr und mehr Eingang in den Alltag, durch immer weitere Anwendungsfelder, wie beispielsweise in der Pflege, finden, wird es wichtig sich mit der Interaktion von Mensch und Maschine zu befassen.
In der ersten Arbeit wurde die Umsetzung der Schnittstelle zwischen Mensch und Maschine behandelt.
Diese Arbeit beschäftigt sich mit der weiteren Entwicklung der Anwendung und im speziellen mit der Umsetzung der Schnittstelle zu einem mobilen Roboter, der durch das Gesten- und Sprachinterface ferngesteuert werden soll.

Die Autoren Ebner und Werling haben diese Arbeit gemeinsam verfasst, wobei die Kapitel jeweils von einem der Autoren geschreiben wurden. Auf Herrn Ebner entfallen Kapitel 2, 4, 7 und 8 und auf Herrn Werling die Kapitel 1, **??**, 5, 6, und 9.

Inhaltsverzeichnis

1 Einleitung

2 Aufgabenstellung

2.1 Problemstellung und Ziel der Arbeit

Aus dem ersten Teil der Arbeit ging die Entwicklung einer Schnittstelle zwischen Mensch und Roboter hervor. Dabei wurden ein erstes Konzept für die verwendeten Gesten und Sprachbefehle, sowie eine erste Umsetzung Stufe der Softwarearchitektur der Anwendung vorgestellt. Ziel des zweiten Teils ist, mit Hilfe diesen ersten Ergebnissen eine Steuerung eines mobilen Roboters umzusetzen. Dabei werden weiterhin die Bibliotheken *jnect* zur Steuerung der Kinect mittels Java, und *jahmm* zur Nutzung der Hidden Markov Models (HMMs) verwendet. Bislang offen sind die Punkte des zu verwendenden mobilen Roboters und die konkrete Implementierung der Anwendung mit den dafür benötigten Funktionalitäten.
Daraus ergeben sich nun folgende Ziele:

- Analyse verfügbarer Ausführungen von mobilen Robotern
- Auswahl eines Robotermodells anhand gegebener Kriterieen und Voraussetzungen
- Konzeption der Anwendung zur Steuerung des mobilen Roboters
- Implementierung der Anwendung
- Optimierung der Gestenerkennung (optional)
- Benutzerfreundlichkeit (Usability) der Anwendung

Dabei wird von der Problemstellung ausgegangen, dass im Rahmen dieser Studienarbeit die Wahl eines mobilen Roboters nur über vorhandene Modelle von mobilen Robotern möglich ist, die auch an der DHBW Karlsruhe verfügbar sind. Bei dieser Wahl sind auch die vorhandenen Restriktionen aus der bereits gewählten Programmiersprache, Java, zu beachten, da vermieden werden soll, mehrere Sprachen in der Entwicklung zu verwenden.
Das Kernziel, die korrekte Erkennung von Gesten und Sprache hängt von zahlreichen Faktoren ab, und benötigt ein hohes Maß an Testaufwand. Auf das Problem der Feineinstellung dieser Systeme durch empirische Ergebnisse wird eingegangen, ob das Ziel einer optimalen Lösung auch erreicht werden kann, ist ungewiss.

2.2 Geplantes Vorgehen

Aus dem ersten Teil der Studienarbeit ging unter anderem eine modular aufgebaute Rich client platform (RCP) Anwendung hervor. Da die einzelnen Module dieser Anwendung in Form von Eclipse Plugins separat verwendet werden können, kann die Arbeit an den unter 2.1 genannten Zielen, zu einem Großteil unabhängig voneinander in die Anwendung integriert werden.
Zu Beginn der Arbeit muss jedoch die Analyse und die Auswahl eines mobilen Roboters abgeschlossen werden, da eventuell auf Besonderheiten eines speziellen Robotermodells in der Anwendung gesonder eingegangen werden muss.
Nachdem also ein Modell ausgewählt wurde und die diversen Arbeiten an der Anwendung separat durchgeführt wurden, soll durch Tests und Optimierungen die Anwendung benutzerfreundlicher gestaltet werden, um eine höhere Qualität der Mensch-Computer-Interaktion zu erreichen.

2.3 Ausblick

Software die nicht weiterentwickelt wird, deren Fehler nicht behoben werden, die nicht auf Wünsche der User angepasst werden, und deren Funktionen nicht erweitert werden, werden auf kurz oder lang nicht mehr verwendet. Dies soll hier versucht werden, zu verhindern. Bereits während der Arbeiten an der Studienarbeit, steht der vorhandene Code der Anwendung unter einer kollaborativen Versionsverwaltung, wobei die Arbeit natürlich nur von den beiden Autoren durchgeführt wird. Um das Ziel dieser Studienarbeit, eine benutzerfreundliche Steuerung eines mobilen Roboters zu erstellen, über den Zeitraum der Studienarbeit weiter zu tragen, soll der Code der Anwendung im Anschluss der Studienarbeit frei verfügbar sein.

3 Stand der Technik

4 Mensch-Computer-Interaktion

Die Mensch-Computer-Interaktion ist die Lehre der Interaktion zwischen dem Menschen (dem Benutzer) und Computern. Dieser Begriff ist nicht zu verwechseln mit Mensch-Maschine-Schnittstelle oder Benutzerschnittstelle, die Teil des Fachbereichs Mensch-Computer-Interaktion sind.
Einer der Wegbegründer auf diesem Gebiet war J. C. R. Licklider. Unter der Bezeichnung *Man-Computer Symbioses* hatte er bereits 1960 Ziele und Probleme dieses Teilgebiets der Informatik postuliert [Lic68].

4.1 Man-Computer Symbiosis

Unter Man-Computer Symbiosis verstand Licklider die Entwicklung einer kooperativen Interaktion zwischen Mensch und Computer. Dabei soll eine enge Partnerschaft zwischen Mensch und den elektronischen Geräten geschaffen werden, so Licklider weiter. Vergleichbar heute mit den fortgeschrittenen Smartphonemodellen, die dem Nutzer nicht nur das Telefonieren ermöglichen, sondern auch Internetzugang bereitstellen, als Navigationssystem dienen, und als Spielekonsole fungieren, und aus diesen Gründen für viele Menschen unersetzlich sind. Weiterhin sind zwei Ziele bei einer Symbiose nach Licklider zu erreichen:

1. Computern formuliertes Denken zu ermöglichen

2. Kooperation in der Entscheidungsfindung und der Handhabung von komplexen Situationen von Mensch und Computer, ohne inflexible Abhängigkeiten auf vordefinierte Programme.

Zum damaligen Zeitpunkt bestanden einzelne Rechner aus meterlangen Schranken, die ganze Räume umfassten und über spezielle Terminals gesteuert wurden, die dazu noch einen Bruchteil der Rechenleistung heutiger Mobilgeräte besitzen. Durch den rasanten Wandel der IT-Welt sind daher nicht mehr alle Erkenntnisse für heutige Anwendungen interessant.

4.2 Anwendung des Konzepts auf das Projekt

Im Rahmen der hier dargestellten Anwendung ist es wichtig das Konzept der Man-Computer Symbiosis von dem abzutrennen, was North [**?**] als *mechanically extended man* bezeichnet. Dabei gibt der Benutzer alle für die Handlung entscheidenden Kriterien, wie Richtung, und Integration vor. Die mechanischen Teile stellen ausschließlich eine Erweiterung des Benutzers dar. Die Anwendung soll zwar aus einer Steuerung für einen mobilen Roboter bestehen, es sollen aber noch weitere Elemente enthalten sein, die über den Typ einer Erweiterung hinaus gehen und eine From von Symbiose erreicht werden kann.
Ein Ziel dabei ist nach Licklider [Lic68], den Computer effektiv in Prozesse des *Denkens*, die in Echtzeit ablaufen müssen, zu integrieren. Aufgrund der Tatsache, dass Computer heut zu Tage aus mehreren Komponenten bestehen und auch zum Großteil durch ihre Perepherie bestimmt sind, die wiederum Rechenleistung des Computers zur vorgesehenen Nutzung benötigt, erweitern wir die Aussage von Licklider auf alle Komponenten, die an der Beziehung teilhaben. Diese werden im Folgenden näher betrachtet.

4.2.1 Die Anwendung RoCoVoMo

In der Anwendung *RoCoVoMo* geschieht dies durch die eingebaute Analyse der Gesten- und Sprachinformation durch HMMs. Die Komponenten Kinect und mobiler Roboter sind separate Teilnehmer der Mensch-Computer-Interaktion. Dabei unterstützt die Anwendung den Nutzer durch die stochastischen Auswertungen der Kinect-Daten und die intuitive Führung durch die Anwendung, in dem Gesten- und Spracherkennung dargestellt und entsprechend an dem mobilen Roboter weitergeleitet werden, und im Ernstfall(Blockade der Räder, fahren gegen ein Wandstück) gesonderte Routinen von der Anwendung ausgeführt werden, ohne das der Nutzer hierbei eingreifen kann, oder sollte. Eine Beschreibung der Anwendung und weitere Details zu deren Implementierung können unter Kapitel 7 und Kapitel 8 nachgelesen werden.

4.2.2 Eingabe- und Ausgabegeräte

Kinect

Die Kinect Komponente besitzt herkömmlichen Eingabegeräten gegenüber einige klare Vorteile in Bezug auf die Mensch-Computer-Interaktion. So kann mittels Kinect, ein Teil der formulierten Denkens, wie Licklider es nennt, auf den Computer übertragen werden, indem der Mensch Gesten und Sprachbefehle verwenden kann, die für den Menschen intuitiver zu handhaben sind, und darüber die Umsetzung der gewünschten Aktion dem Computer überlassen wird. Diese kann, der jeweilgen Aktion entsprechend, komplexe Funktionen umfassen, die der Mennschen nicht notwendigerweise durchführen muss. Dabei wird zugleich das zweite Ziel in Lickliders Man-Computer Symbiosis Symbiosis erfüllt, in dem durch die Gestensteuerung unnötige Zwischenschritte, wie diverse Auswahldialoge oder gesonderte Eingabegeräte zu einem Großteil ersetzt werden, und sogleich ein hohes Maßan Kooperation zwischen Mensch und Computer erreicht werden kann.

Mobiler Roboter

Der mobile Roboter wird direkt über die Anwendung RoCoVoMo gesteuert, und durch die Kinect-Steuerung soll die Verbindung zwischen Mensch und mobilen Roboter unmittelbar gestalten. Fr̈ den Roboter bedeutet dies, ein hohes Maßan flexibilität bezüglich Latenzzeit, Beschleunigung, und Bewegungsrichtung. Der Roboter muss unmittelbar reagieren, sobald eine Geste oder ein Sprachbefehl erkannt wird, so wie eine schnelle Bewegung gewünscht ist. Bezüglich Bewegung ist ein holonomer Roboter eine optimale Voraussetzung für eine intuitive Steuerung und einfache Gestenbefehle.

4.2.3 Mensch - User

Für eine effektive Mensch-Computer-Interaktion ist es für den Nutzer der Anwendung notwendig, einfach und schnell Gestenbefehle einzugeben, die genauso schnell in von der Anwendung in Aktionen umgesetzt werden sollen. Hierbei ist aber ebenso ein gewisses Training des Users nötig, da Gesten- und Sprachbefehle nicht die einfachste Form der Steuerung sind. Der Nutzer muss möglichst klar und ohne Dialekt Sprachbefehle geben, sowie er auch das Vokabular, dass die Anwendung umfasst, kennen muss.
Zu Beachten ist, das Sprache eine redundante Form der Kommunikation ist, und Befehle für den untrainierten Nutzer eine andere Aktion der Anwendung suggerieren, als die in Wirklichkeit der Fall ist.
In Hinsicht auf Gesten, ist es wichtig, dass der User konzentriert und in möglichst konzentrierter Haltung Gesten ausführt. Soweit Gesten simpel und intuitiv gewählt wurden, ist es mit wenig Trainer möglich die Anwendung über Gesten zu steuern. Jedoch muss sich der Nutzer sich soweit auf die Anwendung konzentrieren, in dem er sich bewusst sein muss, dass jede Bewegung, die er während aktiver Gestensteuerung ausfübt von der Anwendung wahrgenommen und analysiert und somit die Möglichkeit besteht, eine Aktion der Anwendung zu initiieren ohne dies beabsichtigt zu haben.

4.3 Herausforderungen der Mensch-Computer-Interaktion

Licklider beschreibt weiter Probleme und Herausforderungen der Man-Computer Symbiosis und der Mensch-Computer Kommunikation [LC62]. Auch wenn sich einige der Probleme heutzutage als neglierbar herausstellen, zeigt es doch einige Punkte auf, die bei der Konzeption einer Mensch-Computer-Interaktion zu beachten sind, denn selbst heute noch, werden Aufgaben, die schwer zu automatisieren sind, dem Menschen oft nur aus diesem Umstand übertragen, obgleich es sinnvoller wäre dies dem Computer zu überlassen und dem User nur die Aufgaben zuzuweisen, die für passend sind.
Da der Mensch in der Anwendung RoCoVoMo nicht einfach nur Bediener ist, sondern auch und vor allem zu erst den Umgang mit Gesten lernen muss stellen sich hierdurch auch eine Probleme, die behandelt werden müssen. Licklider betont hierbei insbesondere den kontinuierlichen Informationsaustausch zwischen Mensch und Computer. Das wichtigstes Nebenziel ist, so Licklider weiter, die Zufriedenheit, den Spaß und die Bestätigung des Nutzers zu maximieren. In der modernen IT-Welt würde man dies mit dem Begriff *Gamification* verbinden, in dem ner Nutzer positive Ressonanz durch seine Aktionen erfährt.
In Hinsicht auf den Informationsaustausch ist aber gleichzeitig darauf zu achten, diesen für den Menschen verständlich und zugänglich zu gestalten. In der Anwendung RoCoVoMo beispielsweise, ist sollten die Körperelemente in einer Grafik angezeigt werden und nicht deren Koordinaten ausgegeben werden. Weiteres zu dem Konzept, das aus den hier geschilderten Problemen ensteht, ist in Kapitel 7 vermerkt.
Von den fünf Problemen, die Licklider schildert [LC62], sind nur noch zwei in Hinsicht auf moderne Anwendungen und die Gestensteuerung als Ausgangspunkt von Interesse:

1. Entwicklung eines Programms das es ermöglicht Echtzeitdaten zu verarbeiten und Informationsverarbeitungsprezesse zwischen Mensch und Computer unterstützt. Das Sysyem muss weiterhin *train-and-error* Operationen erlauben. Es muss weiter mit fehlerhaften Eingaben dynamisch umgehen können.

2. Lösung des Problems der Kooperation von Menschen untereinandner bei der Entwicklung großer Anwendungen. Ohne effektives Teamwork ist Man-Computer Symbiosis nicht möglich, in dem Sinne, das verschiedene Anwendungsbereiche auf verschieden konzipiert sein können und somit Unterschiede im Design und des Programms und Verwirrungen bei Nutzer auftauchen. Wenn beispielsweise der 'Schließen'-Button in einem Modul links, in einem anderen rechts liegt, weil verschiedene Entwickler diese implementiert haben, so ist keine intuitive Führung durch die Anwendung mehr möglich.

4.4 Moderne Design Prinzipien

Eine aktuelle Analyse der Mensch-Computer-Interaktion führt Vikas Chahar [Cha12] durch. Dabei wird Mensch-Computer-Interaktion als die Überschneidung von Informatik, Verhaltenswissenschaft, Design und weiterer Wissenschaftsfeldern beschrieben. Sie beinhaltet Software und Hardware und und findet auf der Ebene der Benutzerschnittstelle statt. Weiterhin ist *MCI* auch von der Ergonomielehre abzugrenzen, die grö ßeren Fokus auf ein physische Ebene richtet.
Betrachtet man nun eine solche Benutzerschnittstelle (*eng. user interface*), so führt Chahar folgende Prinzipien auf, die zu beachten sind:

- Ein früher Fokus auf Benutzer und Aufgaben: Es ist zu ermitteln, wie viele Nutzer, welche Aufgaben ausführen müssen und wie diese Aufgaben zu modellieren sind
- Empirische Messungen: Das Interface früh mit Nutzern testen, die die Anwendung auch tatsächlich benutzen werden. Dabei ist es hilfreich statistische Auswertungen durchzuführen
- Iteratives Desgin: Den vorherigen Punkten anschließend, sollten folgende Schritte iterativ durchgeführt werden:
    1. Benutzerschnittstelle (re-)designen

2. Anwendung testen

3. Ergebnisse analysieren

4.5 Design Methodik

Diverse Methodiken verschiedener Techniken für Mensch-Computer-Interaktion existieren, meist daraus entstanden, wie Nutzer und technisches System interagieren. Aufgrund der vorliegenden Gesten- und Sprachsteuerung, stellt sich ein benutzerzentriertes Design (*eng. User-centered design (UCD)*) als sinnvoll heraus, da die Anwendung durch diese Befehle vom Nutzer aus bedient wird.

- User-centered design: UCD beruht auf der Idee, dass der Nutzer im Zentrum des Design einer Computer Anwendung steht. Dabei werden Wünsche, Notwendigkeiten und Grenzen des Benutzers eroiert und die Anwendung diesen Elementen entsprechend erstellt.
- Prinzipien für Benutzerschnittstellen (*eng. User Interface*) Design: Nach Chahar [Cha12] existieren sieben Prinzipien, die bei dem Design eines user interface zu jeder Zeit berücksichtigt werden sollten, nämlich Toleranz, Simplizität, Sichtbarkeit, Konsistenz, Struktur, Feedback, und Aufwand.

Oft werden diese Prinzipien und Begriffe verwendet, in dem man eine Anwendung einfach als ïntuitiv"bezeichnet. Jedoch ist die Bezeichnung intuitiv kein technischer Indikator für eine gute Man-Computer Symbiosis, da dieser stets unterschiedlich ausgelegt und bestimmt wird. Jef Raskin [Ras94] beschreibt den Begriff intuitiv in Bezug auf Mensch-Computer-Interaktion als ein Synonym für etwas bekanntes. In einem Beispiel, an einer Anwendung, die mit einer Computer Maus gesteuert wird, zeigt er, dass dieses Peripheriegerät erst dann *intuitv* in einem Programm nutzbar ist, sobald die Handhabung der Maus bekannt ist. In Bezug auf die Gesten- und Sprachsteuerung bedeutet dies, dass dem Nutzer erst das sprachliche Vokabular und die verwendbaren Gesten bekannt sein

müssen, bevor an eine dem Nutzer leicht fallende Verwendung der Anwendung zu denken ist.
Ebenso wichtig ist das Display Desgin. Zum Einen ist es wichtig, dem Nutzer alle nötigen Informationen und Rückmeldungen über und von der Anwendung anzuzeigen, zugleich muss vermieden werden, den Benutzer mit zu vielen Anzeigen und einem überladenen Bildschirmbereich zu verwirren.
Die Umsetzung und Auswirkung in der Anwendung RoCoVoMo all der zuvor aufgezeigten Prinzipien und Methoden werden im Kapitel 7 im Detail und an weiteren Beispielen beschrieben.

5 Auswahl des Roboters

5.1 Mobile Roboter

Diese Arbeit beschäftigt sich mit der Steuerung eines Roboters aus der Ferne. Als Steuerungsinterface wird in diesem Fall jedoch kein traditionelles Interface, wie beispielsweise ein Joystick, verwendet, sondern es kommt das, im ersten Teil dieser Studienarbeit vorgestellte Interface, dass auf Sprach- und Gestensteuerung basiert zum Einsatz.

5.2 Mögliche Robotermodelle

5.3 LEGO Mindstorms NXT

Im Rahmen dieses Projektes wird der NXT 2.0 aus der Lego Mindstorm Serie eingesetzt. Im Kontext dieser Arbeit sind keine Sensoren notwendig, da der Roboter aus der Ferne gesteuert wird.

6 Programmierung des Lego Mindstorms NXT

6.1 Programmierung

Die Programmierung des NXT findet mittels der Entwicklungsumgebung NXT-G statt. Hierbei handelt es sich um einen grafischen Editor, mit dessen Hilfe die Logik des Roboters umgesetzt werden kann. Die Sensoren und Aktoren des Lego Roboters werden als Blöcke dargestellt, über die verschiedene Einstellungen vorgenommen werden können. Weitere Blöcke unterstützen simple Programmlogiken wie Schleifen und Bedingungen. Hiermit soll das Blockbausystem von LEGO immitiert, sowie ein leichter Einstieg in die Programmierung des Roboters geschaffen werden. In Abbildung 6.1 ist ein Ausschnitt eines Programms in der graphischen Oberfläche des Editors zu sehen.

Abbildung 6.1: Oberfläche der Entwicklungsumgebung NXT-G (Quelle: debacher.de/wiki/NXT-G.[1])

Mit Hilfe dieser Anwendung ist zwar eine leichte Programmierung des NXT möglich, ist aber für dieses Projekt nicht sinnvoll einsetzbar. Die Firmware des NXT, sowie die Spezifikation der Sensoren und Aktoren, wurden von Lego veröffentlicht. Darüber hinaus auch diverse Developer Toolkits. Durch diese Unterstützung sind eine Vielzahl an Frameworks in verschieden Programmiersprachen und Umgebungen entstanden mit denen der NXT-Baustein programmiert oder auch aus der Ferne gesteuert werden kann.

6.2 Auswahl eines Frameworks

In dieser Arbeit soll nach Möglichkeit eine Umsetzung in der Programmiersprache Java erarbeitet werden. In der nachfolgenden Tabelle 6.1 ist eine Auswahl an Frameworks zu finden, welche eine solche Umsetzung in der gewünschten Sprache erlauben.

Tabelle 6.1: Java Frameworks zur Programmierung des NXT[2]

Framework	**Sprache**
NXTGCC[3]	C/C++, Objective-C, Fortran, Java, Ada, others
leJOS[4]	Java
TinyVM[5]	Java
Gostai Urbi[6]	URBI, C++, Java, Matlab

Durch das erste genannte Framework NXTGCC, also einen Compiler, ist die Programmierung des Bausteins auf einer sehr hardware-nahen Ebene möglich. Dies bedeutet jedoch auch einen sehr hohen Aufwand bei der Umsetzung des vorhabens.

leJOS ist ein sehr ausgereiftes Framework zur Programmierung des NXT mit Java. Der Code wird auf einer eigens entwickelten Firmware auf dem NXT ausgeführt. Außerdem ist auch Codeausführung von einem Computer möglich. Da dies das Framework ist, welches zur Verwendung in dieser Arbeit ausgewählt wurde, wird es im nachfolgenden Kapitel näher beschrieben.

TinyVM kann eigentlich von vorneherein ausgeschlossen werden, da es sich nur zur Programmierung des RCX Bausteins von Lego handelt. Es wird hier jedoch trotzdem erwähnt, da der RCX der Vorgänger des NXT ist, sowie auch TinyVM der Vorläufer

des zuvor genannten NXT darstellt. Wie auch bei leJOS bringt TinyVM eine eigene Firmware für den Lego Roboter mit.

Urbi ist kein eigenes Framework zur Ansteuerung des Lego Roboters selbst, sondern eine Open Source Platform die sich der Steuerung von Robotern und komplexen System im allgemeinen zuwendet. Für den NXT existiert hier eine Schnittstelle. Da es sich hier um ein großes Framework mit sehr weitem Anspruch handelt wird von der Verwendung dieses Frameworks abgesehen.

6.3 leJOS - Java for LEGO Mindstorms

leJOS bietet eine breite Palette an Tools zur Programmierung des NXT mit der Programmiersprache Java. leJOS ging als Open Source Projekt aus TinyVM hervor, welches von José Solrzano entwickelt wurde. Kern von leJOS ist die Umsetzung der Java Virtual Machine auf dem NXT Baustein. Diese ist notwendig um Java Code überhaupt erst auszuführen. Die umgesetzten Features werden auf der Website wie folgt beschrieben[7] :

- Object oriented language (Java)
- Preemptive threads (tasks)
- Arrays, including multi-dimensional
- Recursion
- Synchronization
- Exceptions
- Java types including float, long, and String

[7] „NXJ - Technologie“. lejos.sourceforge.net. Abgerufen Mai 22, 2013

- Most of the java.lang, java.util and java.io classes
- A Well-documented Robotics API

Die erwähnte Robotics API ist die NXJ API. Sie stellt die Schnittstelle zu den Aktoren und Sensoren, sowie den Funktionen des Bausteins, wie beispielsweise Bluetooth, des Lego Roboters dar. Zur Verwendng muss die leJOS Firmware auf dem NXT installiert werden. Dies ist durch mitgelieferte Tools leicht möglich. Zur Entwicklung bringt das Framework ein Eclipse-Plugin mit sich, dies ist hilfreich, da die Entwicklung in diesem Projekt ebenfalls mit Eclipse erfolgt.

Die API ist auf zwei Arten realisiert. Einmal zur direkten Verwendung auf dem Baustein und zum anderen zum Ansteuern des NXT aus der Ferne. Es können also Programme zur direkten Ausführung auf dem Roboter oder über das Remote-Interface, zur Ausführung aus der Ferne mittels Bluetooth entwickelt werden. In der Verwendung ist hier keine andere Herangehensweise erforderlich. Es muss lediglich die entsprechend gewünschte Implementierung der API verwendet werden. Zur Verwendung der Bluetooth-Kommunikation ist auch kein erheblich großer Aufwand notwendig, dies wird komplett durch das Framework übernommen.

Das Framework wurde ausgewählt, da es viele Funktionen bereits abdeckt und somit erlaubt, sich im wesentlichen auf das Implementieren der gewüenschten Funktionen zu beschränken. Ebenfalls ist die Verwendung in ausführlicher Dokumentation geschildert.

7 Konzept und Steuerung der Anwendung

Ein Großteil der ersten Arbeit [EW13] betrafen die Konzeption und Entwicklung von Gesten- und Sprachbefehlen, die innerhalb einer Anwendung zur Steuerung eines mobilen Roboters benötigt werden und sinnvoll sind. Diese wurden werden der Arbeiten an der Anwendung nochmals einer Revision unterzogen und nur in Bezug des zugrundeliegenden HMM [BP66] [Rab89] in technischen Parametern für die Implementierung angepasst.
Das gesamte Vokalubar an Gesten- Sprachbefehlen ist fest in der Anwendung RoCoVoMo verankert, und lässt nur durch Anpassungen im Code ändern. Dies ist beabsichtigt, da nur durch diese Begrenzung ein stabiler Gebrauch der Anwendung garantiert werden kann.

7.1 Verwendete Gesten

Gesten, nach Kurtenbach und Hulteen [KH90], die innerhalb der Anwendung genutzt werden sollen, müssen innerhalb eines HMM repräsentiert werden. Aus der Beschreibung des HMM [EW13] müssen daher einige Komponenten in die Anwendung RoCoVoMo integriert werden. Das bedeutet, dass für jede Geste Trainingsdaten vorhanden sein, beziehungsweise in das Programm eingegeben werden müssen, um diese später im laufenden Betrieb zu erkennen.

Die verwendbaren Gesten werden im folgenden noch einmal aufgelistet. Die entsprechenden Klassifikationen und wissenschaftlichen Beschreibungen wurden bereits in der Ausarbeitung von Ebner und Werling [EW13] erörert und werden hier als bekannt vorausgesetzt.

7.1.1 Kreisbewegung

Diese Geste ermöglicht es den *Lego NXT* im Kreis fahren zu lassen. Sobald die Geste über das HMM und die vorhandenen Trainingsdaten abgegelichen wurde, wird die Anwendung die Aktion ausführen. Die Abbildung 7.1 zeigt die idealisierte Darstellung der Geste.

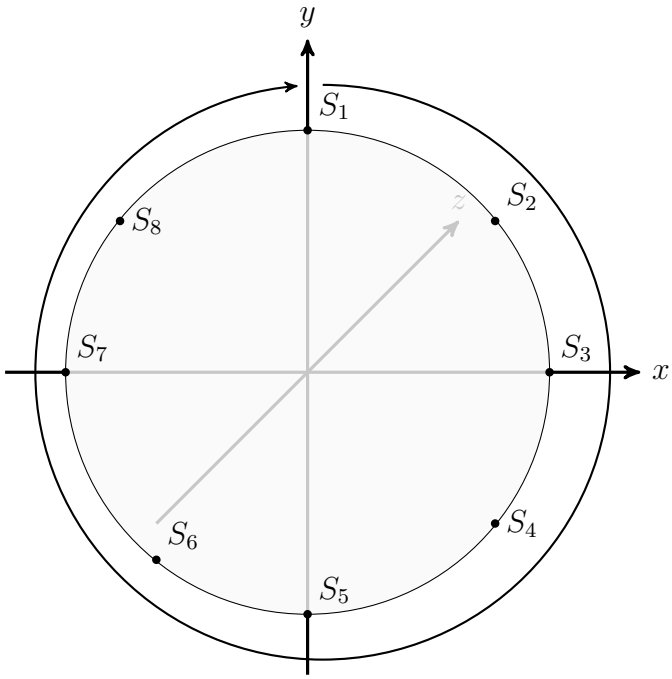

Abbildung 7.1: Abstrakte Darstellung einer Kreisbewegung im Koordinatensystem inklusiver ihrer 8 Zustandspunkte

Aufgrund der restriktionen aus dem mobilen Roboter, in dieser Arbeit der Lego NXT, ist aus dessen Motorspezifikationen und die hier gewälte Bauform, ist es nicht möglich

einen beliebig großen oder kleinen Kreis zu fahren. Weiterhin unterstützt dies die in Abbildung 7.1 gezeigte Geste und das darunterliegende genutzte HMM nicht.

7.1.2 Vorwärtsbewegung

Technisch ist die Vorwärtsbewegung in verschiedene Varianten aufgeteilt. Der Anwendungsnutzer soll bei der Verwendung der jeweiligen Geste aber nichts davon spüren, beziehungsweise, ihm soll diese Aufteilung nicht betreffen.
Dabei wird unterschieden, in der einfachen Variante einer geradlinigen Bewegung, dargestellt in Abbildung 7.2, und zwei erweiterten Gesten, die eine Richtungsänderung beinhalten, dargestellt in den Abbildungen 7.3(a) und 7.3(b).

Standardvariante

Diese Variante beschreibt die Geste für eine geradlinige Vorwärtsbewegung, in einen einfachen Aktionsbefehl für den Lego NXT umgesetzt wird.

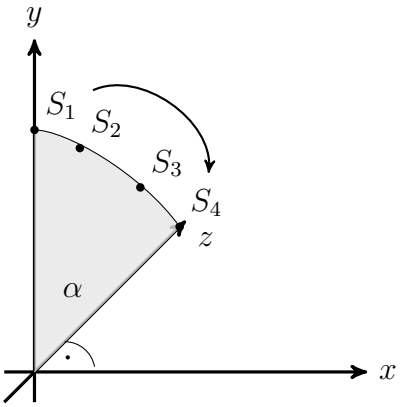

Abbildung 7.2: Abstrakte Darstellung einer Vorwärtsbewegung im Koordinatensystem inklusiver ihrer 4 Zustandspunkte

Die oben beschriebene Vorwärtsbewegung beinhaltet keine Information über einen Winkel, in dem sich der Roboter fortbewegen soll. Um diese Information zu erhalten, muss die Geste und das darunter liegende HMM angepasst und erweitert werden.

Erste Variante der erweiterten Vorwärtsbewegung

Durch die Erweiterung der Standardvariante um eine seitliche Bewegung wird es möglich Richtungsinformationen aus der Geste auszulesen und diese in eine gerichtete Bewegung für den Lego NXT umzusetzen. Dabei ist zu beachten, dass durch die relativ ungenaue Auswertung der Körperelemente durch die Kinect, die Anwendung nicht in der Lage ist einen exakten Richtungswinkel zu ermitteln. Es wird ein grober Richtwert verwendet, der den User bei der anfänglichen Nutzung etwas irritieren kann, was aber mit außreichen Training des Users auf diese Tatsache kompensierbar ist, in dem er eine Richtungsänderung anzeigt.

Zweite Variante der erweiterten Vorwärtsbewegung

In dieser Variante wird bereits mit Beginn der Geste eine Richtungsinformation mitgeliefert. Diese Form der Vorwärtsbewegung ist vor allem für versierte Nutzer gedacht und benötigt auch ein gewisses Training und die zuvor beschriebene Ungenauigkeit zu kompensieren.

7.1.3 Haltesignal

Das Anhalten des Lego NXT ist die wohl wichtigste Aktioin und auch in einer simplen Geste umgesetzt, zumindest für den User, denn auch hier muss auf der technischen Ebene der HMM differenziert werden. Da der Anwendungsnutzer nämlich aus den verschiedenen Formen der Vorwärtsbewegung einen Halt initiieren kann, muss dies auch

beim Haltesignal berücksichtigt werden. Abbildungen 7.5(a) und 7.5(b) zeigen beide Varianten auf.

7.1.4 Entriegeln — Blockieren

Um den Nutzer die Gestensteuerung zu erleichtern, ist es durch eine gesonderte Geste möglich, die Echtzeitverarbeitung seiner Bewegungen zu stoppen und den Lego NXT somit auch automisch zu einem Halt zu bringen. Abbildung **??** zeigt eine idealiserte Darstellung dieser Geste.

7.2 Trainingsmodul

Um die zuvor beschriebenen Gesten zu erkennen, müssen Trainingsdaten in das System eingelesen werden. Hierzu wurde ein Modul entwickelt und in die Anwendung integriert, dass das schreiben und einfügen von Trainingsdaten in RoCoVoMo ermöglicht. Dabei wird dei Kinect in einer Testumgebung gestartet und über das jnect Framework die Daten der gewünschten Geste, beziehungsweise des jeweilgen Body Elements eingelesen. Benötigte Informationen sind dabei nur die Koordinaten des jeweilgen Elements und die Anzahl der verwendeten HMM Zustandspunkte. Das jahmm Framework benötigt für die Errechnung eines HMM besonders gefilterte Daten, daher werden die Kinectinformationen in einem besonderen Format gespeichert, anschließend innerhalb der Anwendung ohne weitere Änderungen verwendet werden können. Die technischen Details dieses Moduls werden näher in Kapitel 8 beschrieben.
In Kapitel 4 wurde beschrieben, welche Merkmale entscheiden sind für eine gute Mensch-Computer-Interaktion und welche Gesichtspunkte berücksichtigt werden müssen. Die Kernfunktion, im Fall des Traininsmoduls, ist das Einlesen von Kinectdaten über ein Interface. Dabei ist das Design und die einfache Bedienung der grafischen Oberfläche sehr wichtig. In dem Modul selbst können zur Bedienung jedoch noch keine Gesten verwendet

werden, dies ist erst im Modul der Robotersteuerung möglich, da zuvor noch keine Trainingsdaten vorhanden sind. Da es sich weiterhin um ein User-centered design handelt ist es wichtig im Sinne der Man-Computer Symbiosis dem Benutzer eine Echtzeitverarbeitung und einfachen Informationsaustausch zu ermöglichen. Dies wird im Modul dadurch verwircklicht, in dem der Nutzer mit der Aufzeichnung seiner Bewegungen direkt und in Echtzeit eine Anzeige seiner Daten erhält und diese darüber hinaus manuell nachbearbeiten kann. Dabei wurde das Interface anhand der in Kapitel 4 vorgestellten Design Prinzipien von Chahar [Cha12] simpel und klar strukturiert und durch die manuelle Nachbearbeitung auf ein hohes Maß an Sichtbarkeit geachtet.

7.3 Kinect—Modul

Als ein Kernelement einer Man-Computer Symbiosis, gilt der Informationsaustausch. Jedoch muss dabei darauf geachtet werden, diesen in einer Form zu gestalten, dass der menschliche Teil der Beziehung dabei nicht von den Ausgaben überfordert wird, und er diese in für ihn passender Form erhält. Im Falle der Gesten- und Sprachsteuerung mittels Kinect, werden zunächst lediglich drei dimensionale Koordinaten der einzelnen Körperelemente übermittelt. Diese sind für den Menschen nur äußerst umstülich zu lesen und stellen keine geeignete Form der Darstellung dar. Daher wurde ein Modul erstellt, dass mittels diesen Koordinaten ein grafisches Bild der Körpers des Menschen mit allen erfassten Elementen anzeigt, deren Koordinaten von der Kinect übermittelt werden. Hiermit wird ebenfalls nahe am User-centered design gearbeitet und die Prinzipien, wie Simplizität und Feedback verfolgt, in dem der Nutzer ein einfaches Bild seiner selbst sieht.
Ein weiteres Merkmal, dass mittels des zugrundeliegenden OSGi-Frameworks möglich ist - bereits in Teil 1 der Studienarbeit [EW13] vorgestellt - ist, dass dieses Modul in jedem Teil der Anwendung aufrufbar ist und der Benutzer zu jeder Zeit Feedback und grafische Informationen über seine Erfassung durch die Kinect erhalten kann. Dies kann auch als Hilfe bei der Modellierung weiterer Gesten, der Weiterentwicklung der Anwendung und

dem Auffinden von Fehlern und Fehlverhalten bei der Erkennung von Gesten und der Umsetzung in die entsprechende Aktion dienen.
Details zur Umsetzung dieses Moduls werden in Kapitel 8 beschrieben.

7.4 Roboterinterface

In diesem Modul kann der User die über Gesten den Lego NXT steuern. Dabei werden Anhand der Trainingsdaten bei Anwendungsstart die diversen HMM aller Gesten generiert und gespeichert. Sobald nun das Interface geöffnet wird, um den Roboter zu steuern, werden eben diese HMM verwendet und mit den Echtzeitdaten aus der Kinect abgegelichen und entsprechend Gesten erkannt und automatisch in Aktionen für den Lego NXT übertragen.
Diese Modul ist ebenso wie die vorherigen nach dem User-centered design konzipiert und richtet sich nach den Design Prinzipien von Chahar. Als besonders wichtig hierbei, stellt sich die grafische Darstellung des Roboters und der Ein- und Ausgabe heraus. Dem Menschen fällt es schwer, sich auf mehrere Dinge gleichzeitig zu konzentrieren, in Bezug auf die Anwendung, auf die grafische Anzeige am Computer und den Lego NXT im Raum. Daher wird mittels einer grafischen Anzeige innerhalb der Anwendung versucht, dieses Problem zu lösen, wobei der Nutzer hierbei nur eine idealisierte Ansicht der Realität vermittelt bekommt, die auch nur die Anzeige des Roboters und dessen Ein- und Ausgabe umfasst, und nicht etwaige Hindernisse im Raum.
Eine entsprechende Lösung dieses Problems, wäre die Installation einer Kamera auf dem Lego NXT, und die Ausgabe dieser Videoinformationen innerhalb der Anwendung.
Alle weiteren Informationen dieses Moduls und dessen Umsetzung in der Anwendung sind in Kapitel 8 zu finden.

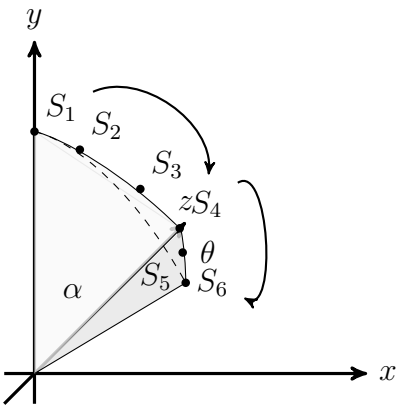

(a) Darstellung der gesamten erweiterten Vorwärtsbewegung mit 6 Zuständen

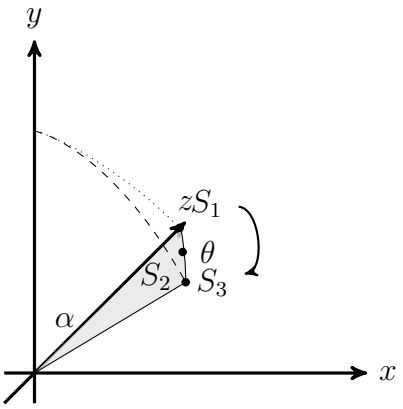

(b) Detaildarstellung der Seitwärtsbewegung der erweiterten Vorwärtsbewegung und ihrer 2 Zustände

Abbildung 7.3: Idealisierte Darstellung der 1. Variante einer erweiterten Vorwärtsbewegung mit 6 Zuständen

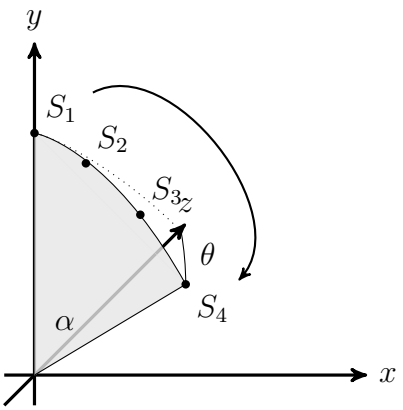

Abbildung 7.4: Idealisierte Darstellung der 2. Variante einer erweiterten Vorwärtsbewegung mit 4 Zuständen

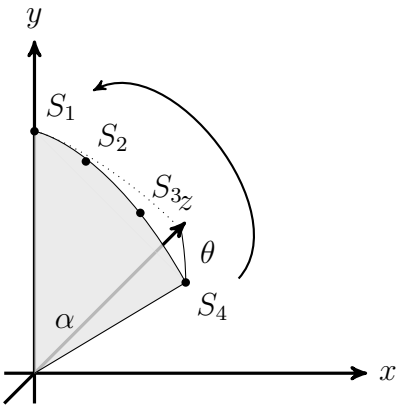

(a) Abstrakte Darstellung des Haltesignals aus einer möglichen Vorwzärtsbewegung heraus, mit ihren 4 Zuständen

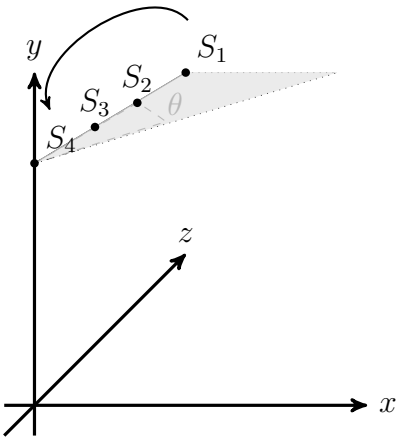

(b) Abstrakte Darstellung des Haltesignals aus einer möglichen Kreisbewegung heraus, mit ihren 4 Zuständen

Abbildung 7.5: Abstrakte Darstellung der Modelle für die Geste des Haltesignals mit jeweils 4 Zuständen

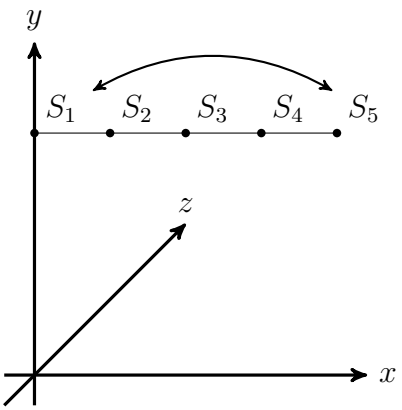

Abbildung 7.6: Idealisierte Darstellung der Geste zum Blockieren und Freigeben der Gesteneingabe mit 4 Zuständen

8 Implementierung

Die Anwendung RoCoVoMo wird in der Programmiersprache Java geschrieben und verwendet diverse Frameworks, die im folgenden kurz beschrieben werden:

- *OSGi*: Ermöglicht die Aufteilung der einzelnen Komponenten der Anwendung in sogenannte *Bundles* oder Module die getrennt voneinander verwendet werden können
- *jahmm*: Liefert alle Algorithmen und Komponenten, die zur Erstellung von HMMs benötigt werden
- *jnect*: Dient als Schnittstelle zwischen Kinect, Kinect SDK for Windows und der Java-Anwendung
- *lwjgl*: Ermöglicht die Verwendung von drei dimensionalen Grafiken der OpenGL Bibliothek

Darüber hinaus wird die gesamte Java-Anwendung innerhalb der Eclipse Integrated development environment (IDE) entwickelt und auf der aktuellen Juno 4.2 Plattform umgesetzt. Die Anwendung selbst wird in Form einer RCP entwickelt und damit das OSGi Framework von Eclipse, Equinox, verwendet.
Im Folgenden werden die einzelnen Bestandteile der Anwendung näher beschrieben.

8.1 Architektur — Design

Seit den Arbeiten an der Anwendung für den ersten Teil der Arbeit wurde das Design und die Architektur der Anwendung nochmals überarbeitet. Abbildung 8.1 zeigt den aktuellen Stand der Anwendung.

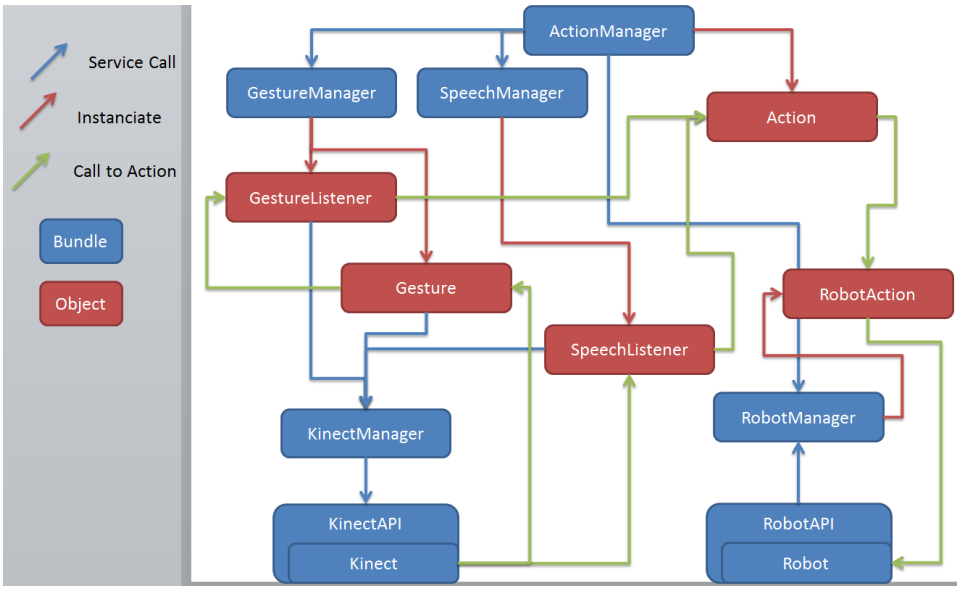

Abbildung 8.1: Architekturdiagramm der Anwendung RoCoVoMo

Die mit der Farbe Blau markierten Elemente stellen sogenannte OSGi-Bundles dar. Dabei handelt es sich vereinfacht gesprochen um einen Container, der eine bestimmte Logik beziehungsweise Fachlichkeit abdeckt und modular verwendbar ist. In der Anwendung RoCoVoMo werden mehrere solcher Bundles verwendet, die im Folgenden weiter beschrieben werden. Mit Rot markierte Elemente sind Java Klassen, die als Objekte innerhalb der Bundles verwendet werden.

8.1.1 ActionManager

In einer sogenannten *Managerklasse*, in diesem Fall dem *ActionManager* werden alle Aktionen verwaltet, die innerhalb der Anwendung ausführbar sind. Die Managerklasse führt dabei selbst keine Fachlichkeit aus, sondern delegiert diese an die darin verwalteten Objektinstanzen weiter, hier den einzelen Aktionen und ebenso an damit verbundene Bundles, hier *GestureManager*, *SpeechManager* und *RobotManager*.
Diese Aufteilung ermöglicht es, Aktionen flexibel in die Anwendung zu integrieren, abzuändern oder gar zu löschen. Weiter ist durch die loose Verbindung über sogenannte *Service Calls*, zum Beispiel des GestureManagers keine Abhängigkeit zu darin verwalteten Gesten vorhanden. Die einzige Verbindung zwischen Gesten und Aktionen findet im GestureListener statt, hierzu später mehr.
Gleiches gilt für Sprache und der Roboteransteuerung.

Action

Die *Action* ist so konzipiert, dass sie nicht direkt von einem Robotertyp abhängig ist. Diese Design ermöglicht sogar den relativ einfachen Umbau der Anwendung und Einsatz eines alternativen Robotermodells zum Lego NXT.
Wird eine Aktion ausgeführt, so ruft diese weiter die *RoboterAction* aus, die die weitere Steuerung des Roboters übernimmt, bisher der Lego NXT. Aufgerufen wird dieses Objekt von den Objekten *GestureListener*, und *Speechlistener*.

8.1.2 GestureManager

GestureManager verwaltet alle in der Anwendung verfügbaren Gesten. Dabei existiert pro *Gesture*-Objekt ein *GestureListener*.

GestureListener

GestureListener liest Kinectinformationen aus und gleicht diese mit den HMMs ab. Dabei werden über spiezelle *Recognizer*-Klassen, die Kinectdaten als HMM-Sequenzen eingelesen und Wahrscheinlichkeitsauswertungen im HMM die richtige Geste erkannt und das entsprechende *Gesture*-Objekt in Folge ausgeführt.

Gesture

Gesture beinhaltet zahlreiche Meta-Informationen über die entsprechende Geste und ist über einen *Actioncall* mit dem zugewiesenen *Action*-Objekt verbunden. Wird das Gesture-Objekt vom Listener ausgeführt, so ruft Gesture diese Aktion auf.

8.1.3 SpeechManager

SpeechManager verwaltet alle Sprachbefehle. Da Sprachbefehle bereits innerhalb der Kinect SDK integriert sind, und dieser lediglich über String-Objekte und der entsprechenden Sprache hinzugefügt werden müssen, wurde darauf verzichtet ein gesondertes Objekt Speech zu modellieren, da dieses ledigliche die String Information enthalten würde. Diese Daten sind im *SpeechListener* hinerlegt.

SpeechListener

SpeechListener führt, sobald ein Sprachbefehl von der Kinect erkannt wurde, das entsprechende *Action*-Objekt aus.

8.1.4 KinectManager

KinectManager verwaltet die Verwendung von und den Datenaustausch mit der Kinect. Dieser wird von den Objekten *GestureListener*, *Gesture*, und *SpeechListener* über Service Calls aufgerufen.
Durch den Manager wird die KinectAPI und darin enthaltene Kinect für alle Teilnehmer sichtbar und dadurch kann ohne direkte Abhängigkeiten auf die Kinectinformationen zugegriffen werden.

8.1.5 RobotManager

RobotManager verwaltet die Verwendung der RobotAPI und des darin enthaltenen Roboters. Bisher wird dadurch der Lego NXT verbunden. Durch diese Architektur ist jedoch auch möglich weitere Robotermodelle in die Anwendung RoCoVoMo zu integrieren und weitere Abhängigkeiten zu erhalten.
Der Manager verwaltet weiterhin die Objekte *RobotAction*, die dann aber je nach Robotermodell individuell geschrieben werden müssen, da diese direkt auf die Roboter Programmierschnittstelle zugreifen, und diese sich von Modell zu Modell unterscheiden kann.

8.2 Trainingsmodul

8.3 Kinect-Modul

8.4 Roboterinterface

9 Ausblick - weitere Arbeiten

Abbildungsverzeichnis

Tabellenverzeichnis

Quellcodeverzeichnis

Literaturverzeichnis

[BP66] E. Leonard Baum and Ted Petrie. Statistical inference for probabilistic functions of finite state markov chains. *The Annals of Mathematical Statistics*, Vol. 37, No. 6:1554–1563, 1966.

[Cha12] Vikas Chahar. An analytical study on hci. *International Journal of Computer Science and Management Studies*, 12(01):251–254, 2012.

[EW13] Simon Ebner and Volker Werling. Gesten- und sprachsteuerung fuer einen mobilen roboter mittels kinect for windows unter java. Vol. 1:1–101, 2013.

[KH90] G. Kurtenbach and E. A. Hulteen. Gestures in human-computer communication. In *The Art of Human-Computer Interface Design*. Addison-Wesley Publishing Co., May 1990.

[LC62] J. C. R. Licklider and Welden E. Clark. On-line man-computer communication. In *Proceedings of the May 1-3, 1962, spring joint computer conference*, AIEE-IRE '62 (Spring), pages 113–128, New York, NY, USA, 1962. ACM.

[Lic68] J. C. R. Licklider. Man-computer symbiosis. In W. D. Orr, editor, *Conversational Computers*, pages 3–5. Wiley, New York, 1968.

[Rab89] Lawrence R. Rabiner. A tutorial on hidden markov models and selected applications in speech recognition. *Proceedings of the IEEE*, Vol. 77, No. 2:257–286, 1989.

[Ras94] Jef Raskin. Viewpoint: Intuitive equals familiar. *Commun. ACM*, 37(9):17–18, September 1994.